RELATÓRIO DE ENTENDIMENTO DOS DADOS

Detecção de Fraudes em Terminais Físicos

Análise Exploratória — EDA

Carlos Magno Bernardino Silva | PoD Academy

1. Visão Geral do Dataset

O dataset é composto por transações de cartão de crédito em terminais físicos (POS), cobrindo o período de agosto a dezembro de 2021 (treino) e janeiro de 2022 em diante (teste). Três tabelas relacionadas formam a base de análise:

- train.csv — transações históricas com label de fraude (TX_FRAUD)
- customer.csv — perfil dos clientes (coordenadas, ticket médio, frequência)
- terminal.csv — localização geográfica dos terminais de pagamento

291.231	226.731	998	1.994	2,26%
Transações (treino)	Transações (teste)	Clientes	Terminais	Taxa de Fraude

Observamos que:

- O dataset principal está 100% preenchido — sem valores nulos em nenhuma variável.
- Os 998 clientes realizaram 291.231 transações em 1.994 terminais distintos.
- A taxa de fraude global é de 2,26%, caracterizando um problema de classes fortemente desbalanceadas.

2. Metadados e Schema

2.1 Tabela principal — train / test

Variável	
TRANSACTION_ID	Identificador único da transação (cardinalidade = 291.231)
TX_DATETIME	Data e hora da transação (ago/2021 a dez/2021 no treino)

CUSTOMER_ID	Chave de junção com tabela customer (998 valores únicos)
TERMINAL_ID	Chave de junção com tabela terminal (1.994 valores únicos)
TX_AMOUNT	Valor da transação em moeda local (float, 18.570 valores únicos)
TX_FRAUD	Variável alvo: 0 = legítima | 1 = fraude (2,26% de fraudes)

2.2 Tabela customer

Variável	
CUSTOMER_ID	Chave primária do cliente
x_customer_id	Coordenada X da localização habitual do cliente
y_customer_id	Coordenada Y da localização habitual do cliente
mean_amount	Valor médio histórico das transações do cliente
std_amount	Desvio padrão do valor das transações
mean_nb_tx_per_day	Média de transações por dia

2.3 Tabela terminal

Variável	
TERMINAL_ID	Chave primária do terminal
x_terminal_id	Coordenada X do terminal
y_terminal_id	Coordenada Y do terminal

---

3. Taxa de Fraude e Volume por Mês de Referência

A tabela abaixo resume o volume de transações e a taxa de fraude observada em cada mês do período de treino:

Mês Referência	Volume Transações	Taxa de Fraude
Ago/2021	59.193	2,28%
Set/2021	57.582	2,42% (máximo)
Out/2021	59.166	2,19%
Nov/2021	57.800	2,07% (mínimo)
Dez/2021	57.490	2,34%

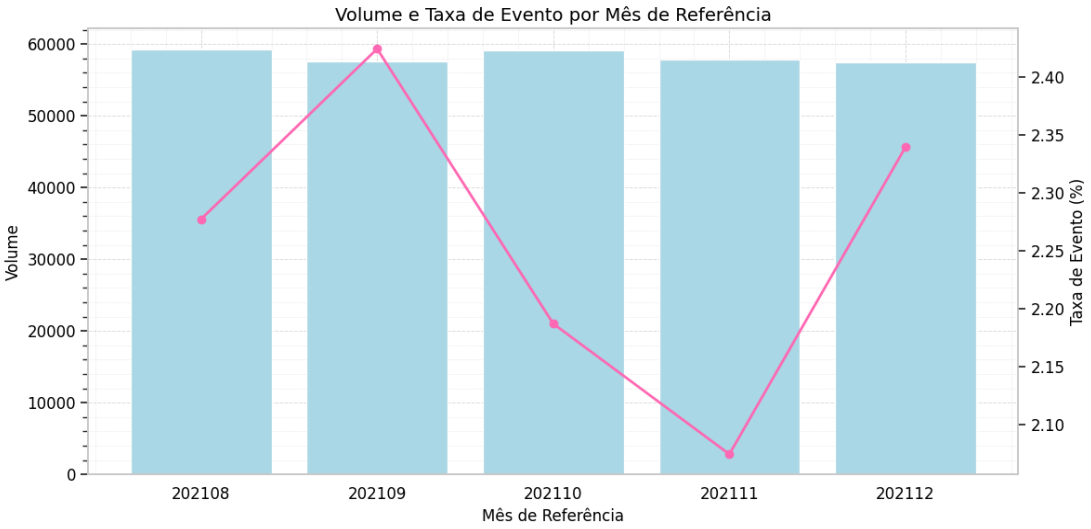

Figura 1 — Volume de transações e taxa de fraude por mês de referência

Conclusão:

- O volume de transações é estável ao longo do período (57–59 mil/mês).
- A taxa de fraude oscila entre 2,07% (nov/2021) e 2,42% (set/2021) — variação contida.
- Não há sazonalidade expressiva que indique um período crítico isolado.

---

4. Análise por Terminal

4.1 Terminais com Maior Taxa de Fraude

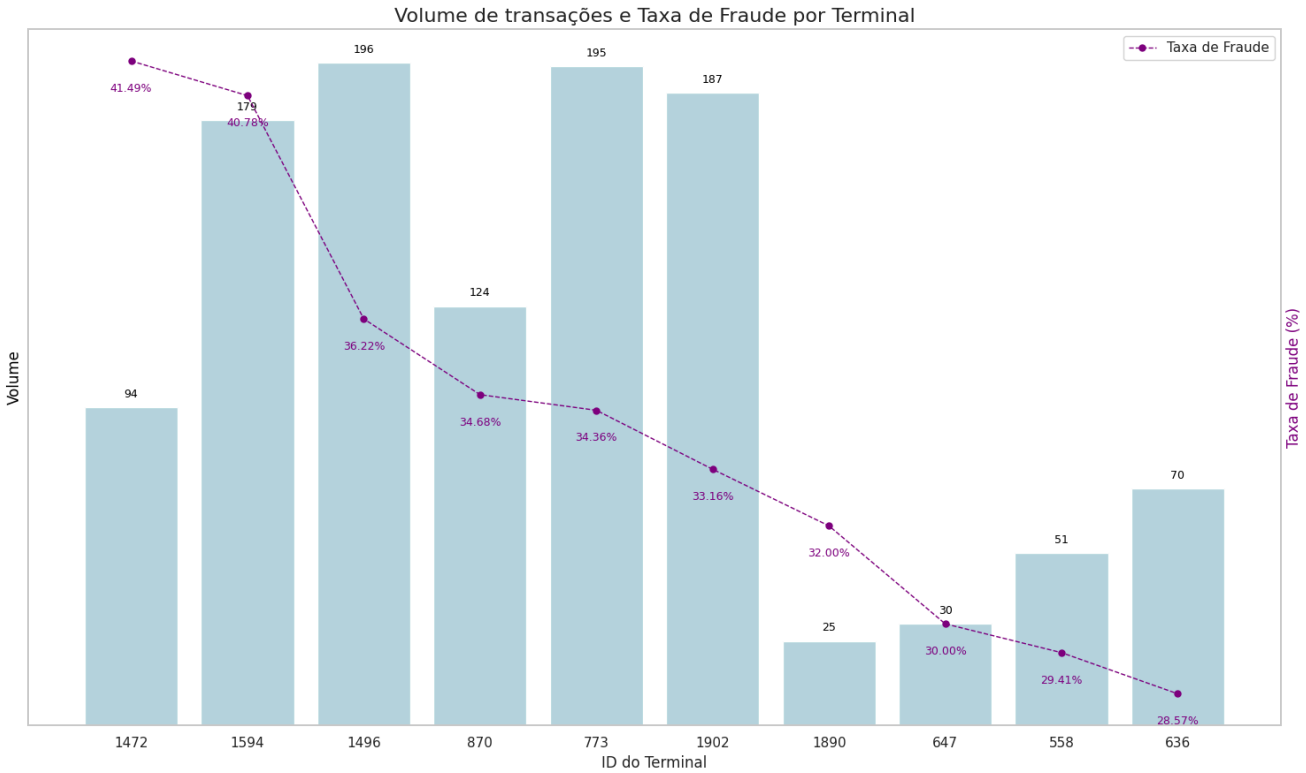

Figura 2 — Top terminais ordenados pela maior taxa de fraude

Os terminais no topo deste ranking apresentam taxas de fraude muito acima da média global (2,26%). Esses terminais são candidatos diretos a regras de bloqueio ou monitoramento intensivo.

4.2 Terminais com Maior Volume de Transações

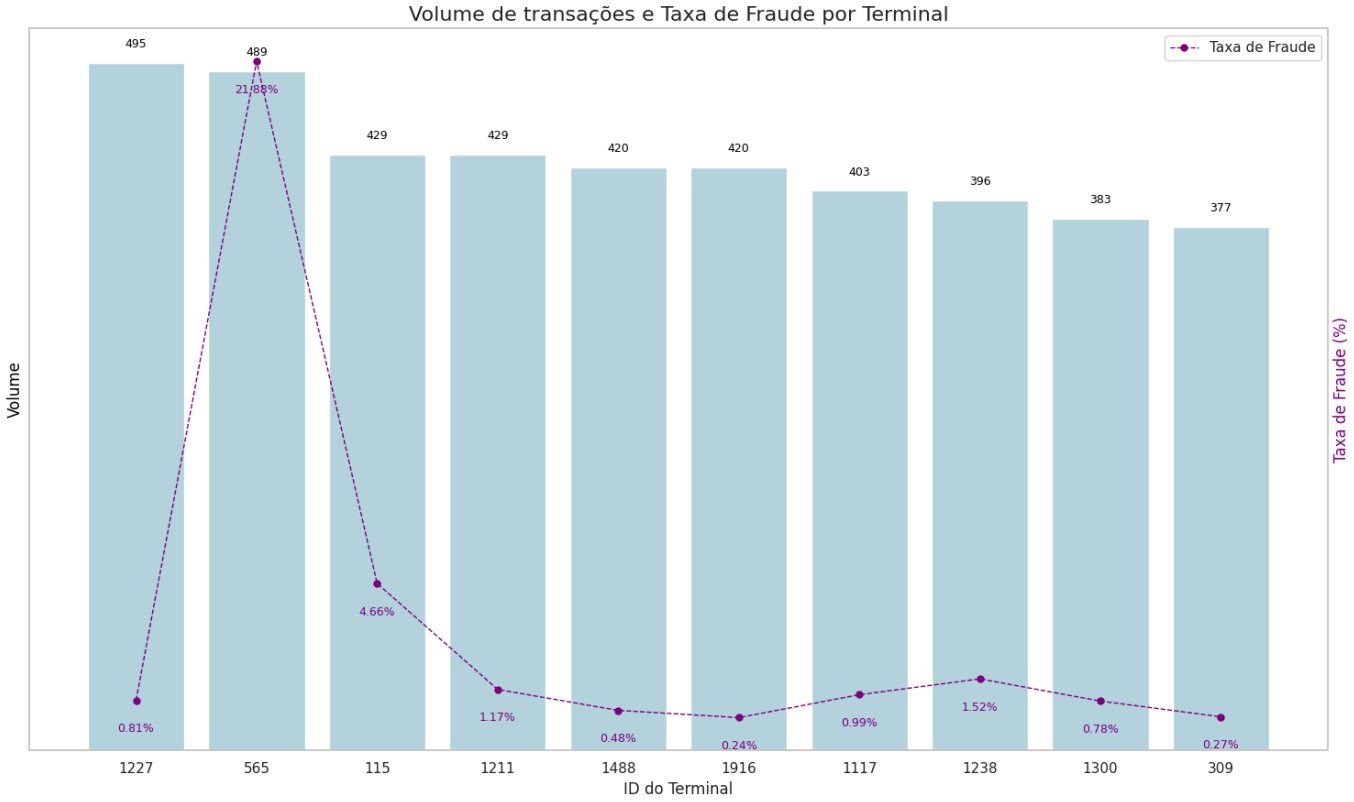

Figura 3 — Top terminais ordenados pelo volume de transações

Destaque — Terminal 565:

489	~21,9%	9,68x
Volume de transações	Taxa de fraude	Razão vs. média

- O terminal 565 possui o 2° maior volume de transações e taxa de fraude 9,68x acima da média global.
- Esse terminal é um sinal forte de comprometimento e deve ser prioridade na modelagem.

---

5. Clientes Envolvidos em Transações Fraudulentas

750 / 998	75,15%	317 clientes	265 clientes
Clientes c/ fraude no período	Representação percentual	Pico mensal (set/2021)	Menor índice (nov/2021)

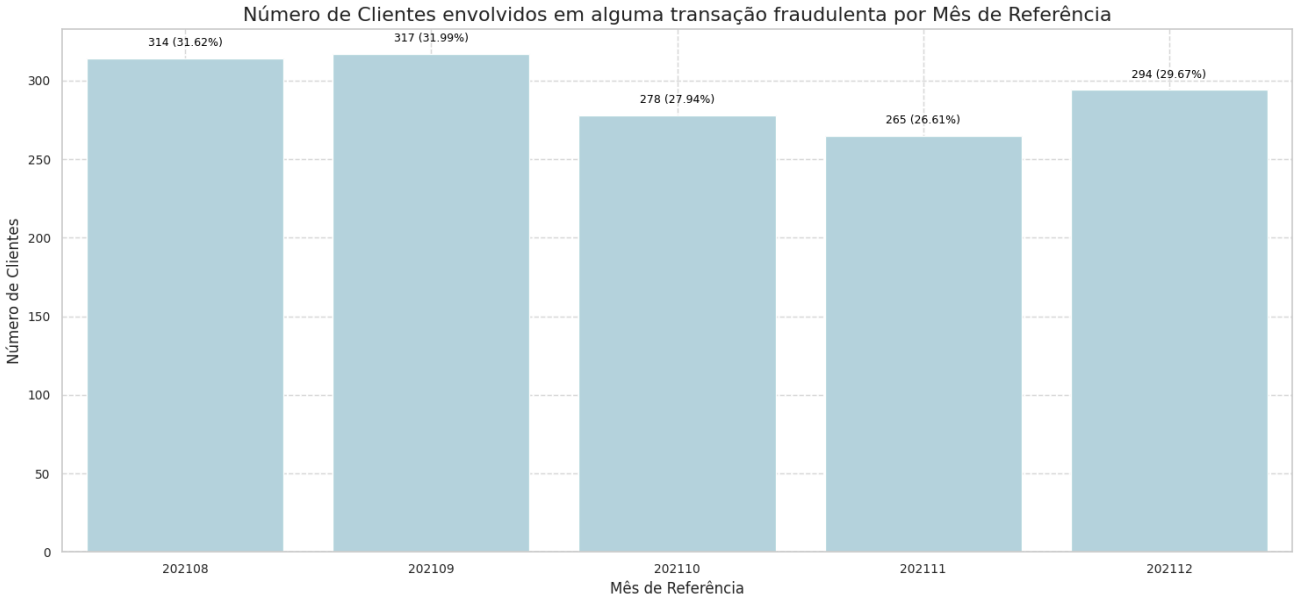

Figura 4 — Clientes envolvidos em fraudes por mês de referência

Conclusão:

- 75,15% dos clientes foram vítimas de ao menos uma transação fraudulenta no período — indicador de exposição sistêmica.
- Em setembro/2021, 317 clientes (31,99% do total ativo no mês) sofreram fraude.
- Novembro/2021 registrou redução para 265 clientes (26,61%), coincidindo com a menor taxa de fraude do período.

---

6. Volume Financeiro das Transações Fraudulentas

R$ 376.210,13
Total fraudado no período

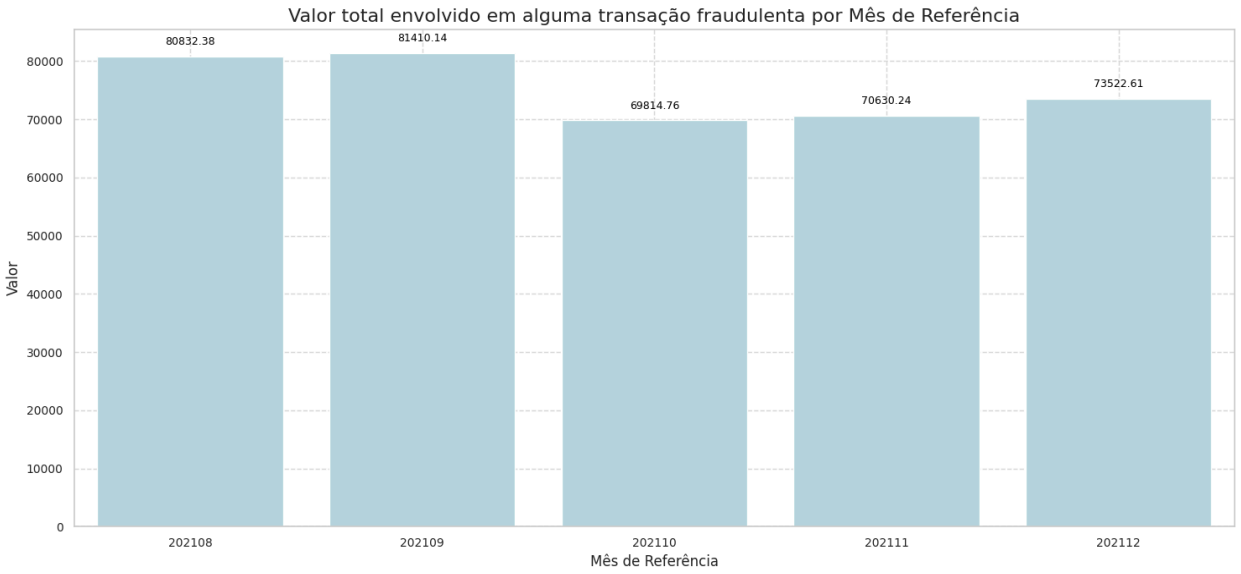

Figura 5 — Volume financeiro mensal das transações fraudulentas

O montante fraudado é distribuído de forma relativamente uniforme ao longo dos meses, sem picos financeiros isolados. Isso reforça que o fenômeno de fraude não é concentrado em eventos pontuais, mas ocorre de forma persistente.

---

7. Distribuição do Valor das Transações (TX_AMOUNT)

7.1 Análise Gráfica — Fraude vs. Legítima

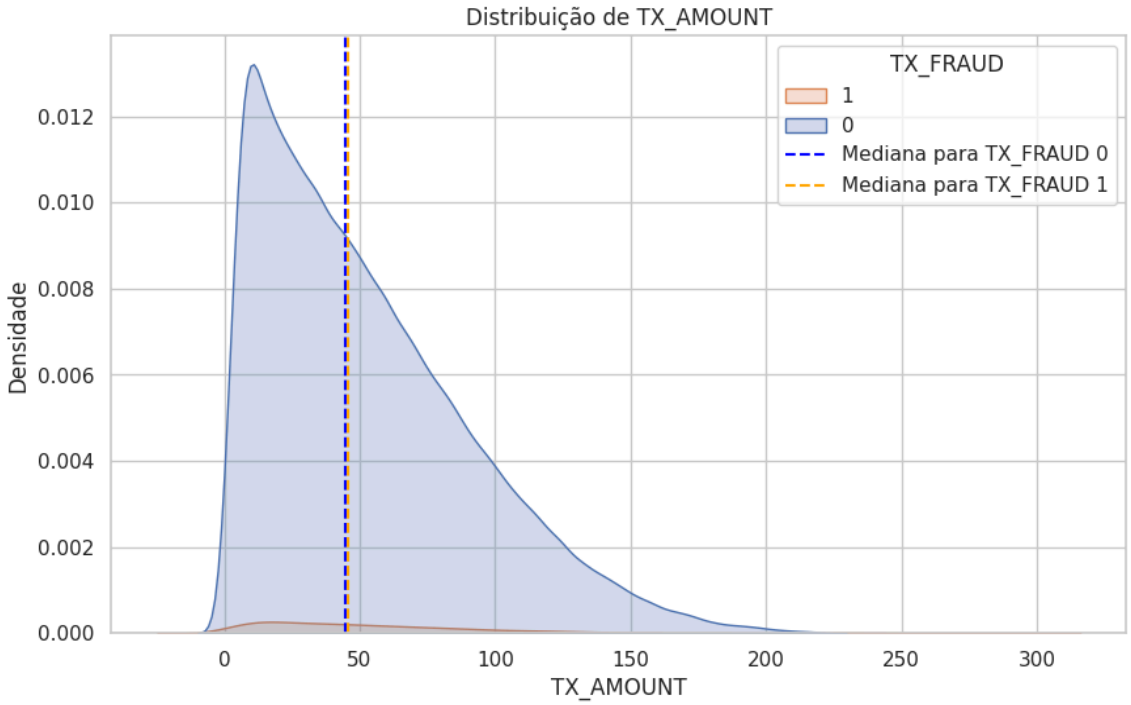

Figura 6 — Distribuição de TX_AMOUNT por grupo (Fraude / Legítima)

A visualização mostra que as distribuições dos dois grupos apresentam diferenças de mediana, com transações fraudulentas tendendo a valores ligeiramente maiores.

7.2 Teste Estatístico — Mann-Whitney U

Para confirmar se a diferença entre os grupos é estatisticamente significativa, foi aplicado o teste de Mann-Whitney U (não paramétrico, adequado para distribuições assimétricas):

918.469.532,5	0,0033	Rejeita H0
Estatística U	Valor p	Conclusão

- H0 (hipótese nula): não há diferença entre os grupos.
- Com p-value = 0,0033 < 0,05, rejeitamos H0.
- Conclusão: existe diferença estatisticamente significativa no valor das transações entre os grupos Fraude e Legítima — TX_AMOUNT é uma feature relevante para o modelo.

---

8. Análise por Período do Dia

Período do Dia	Volume	Taxa de Fraude
Manhã	119.379	2,18%
Tarde	107.666	2,25%
Noite	64.186	2,43% (maior)

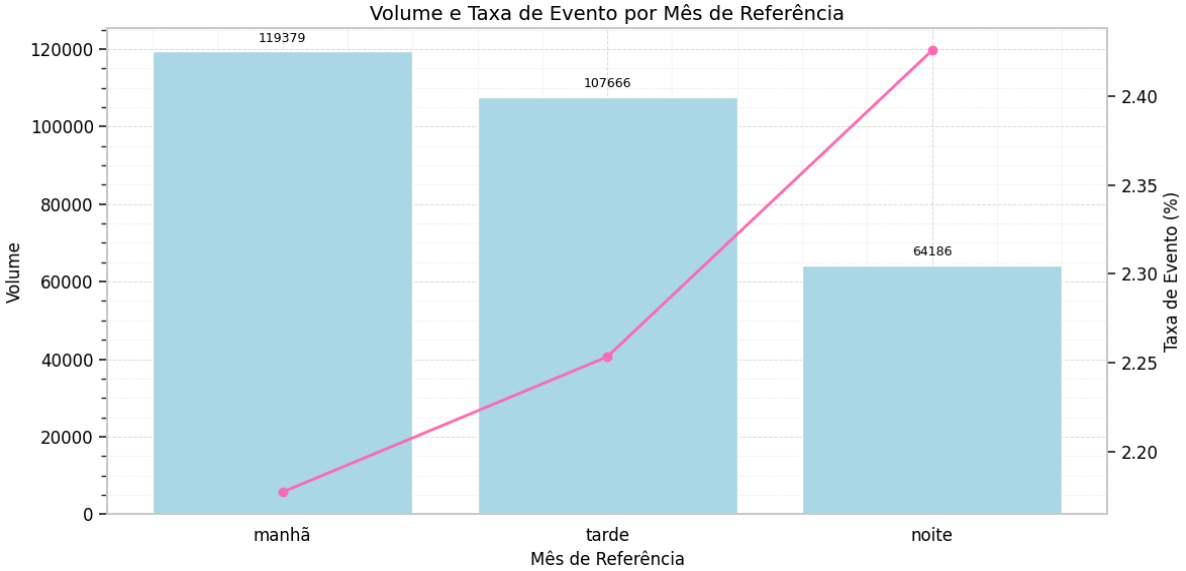

Figura 7 — Volume e taxa de fraude por período do dia

Conclusão:

- O maior volume de transações ocorre pela manhã e tarde.
- A taxa de fraude é mais elevada no período da noite (2,43%), mesmo com menor volume — sinal de oportunidade para fraudadores.
- A feature PERIODO_DIA (ou TX_HOUR) tem potencial discriminativo para o modelo.

8.1 Distribuição de TX_AMOUNT por Período do Dia — Fraude

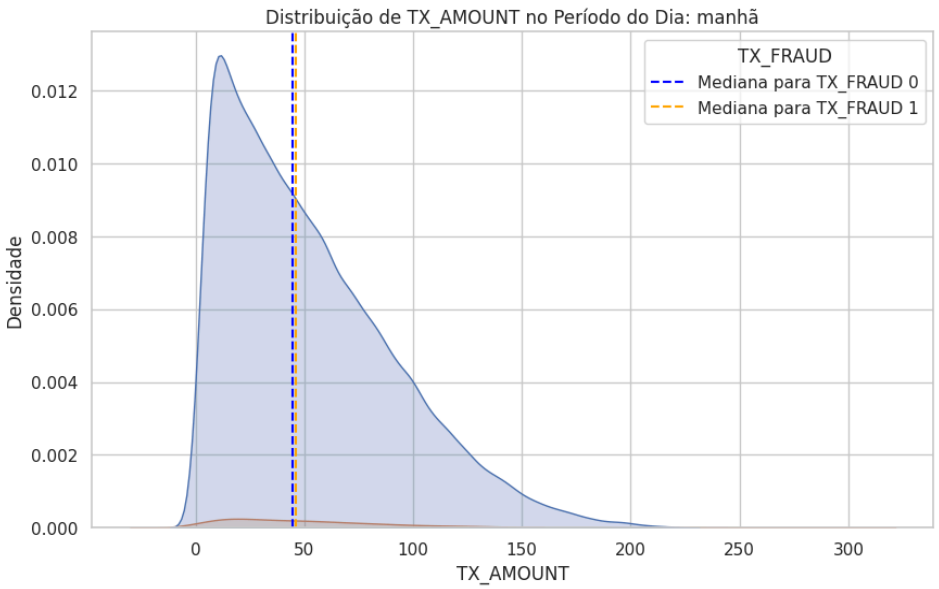

Figura 8a — Distribuição TX_AMOUNT: Transações fraudulentas — Manhã

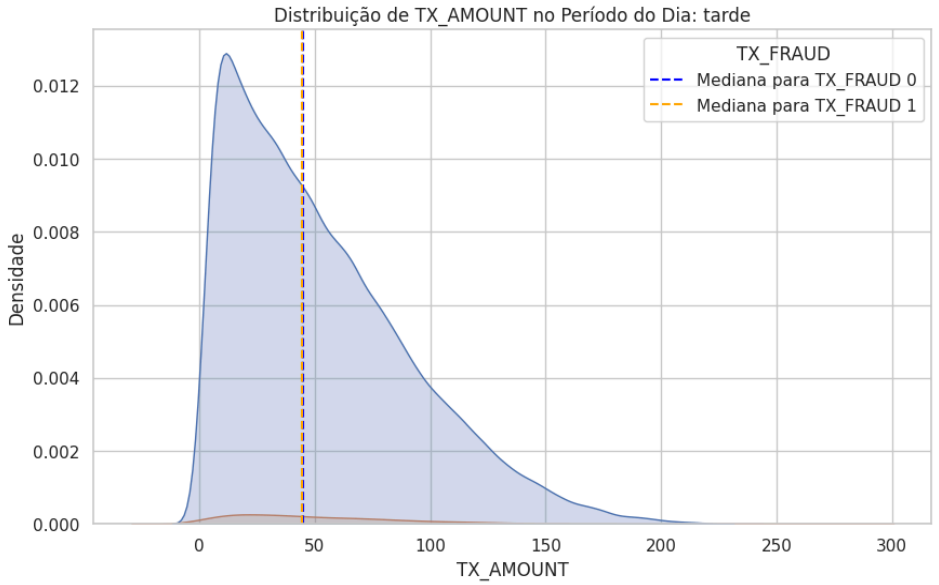

Figura 8b — Distribuição TX_AMOUNT: Transações fraudulentas — Tarde

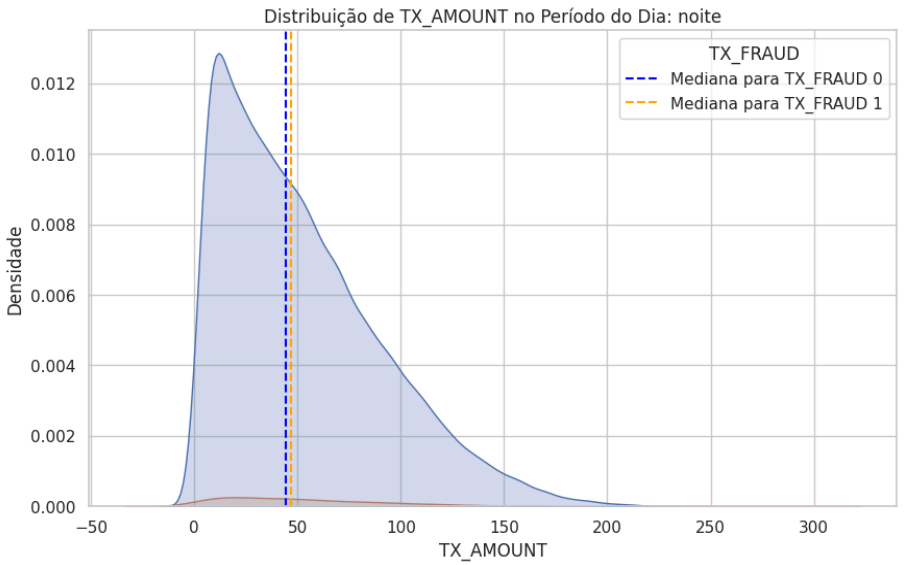

Figura 8c — Distribuição TX_AMOUNT: Transações fraudulentas — Noite

8.2 Distribuição de TX_AMOUNT por Período do Dia — Legítima

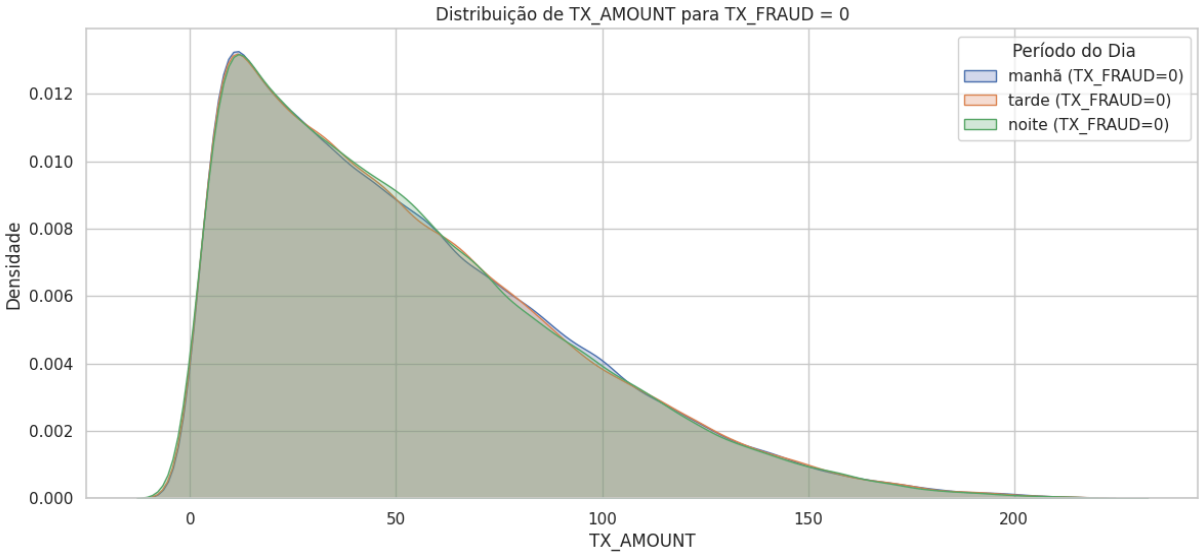

Figura 9a — Distribuição TX_AMOUNT: Transações legítimas (comparativo períodos)

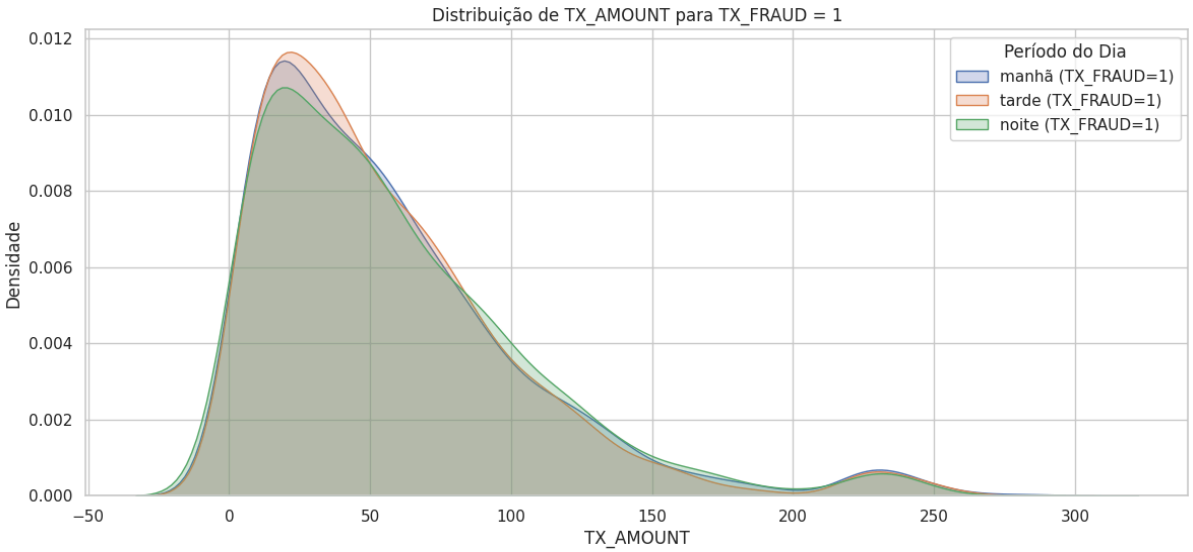

Figura 9b — Distribuição TX_AMOUNT: Transações legítimas por período

---

9. Localização Geográfica de Clientes e Terminais

9.1 Localização dos Clientes

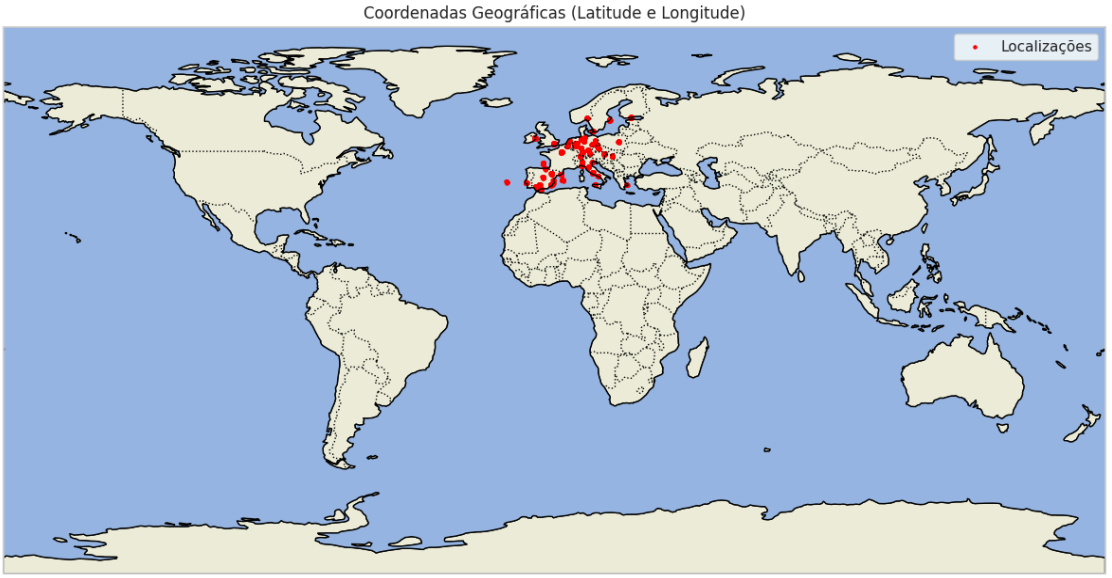

Figura 10 — Mapa de dispersão das localizações dos clientes

9.2 Localização dos Terminais

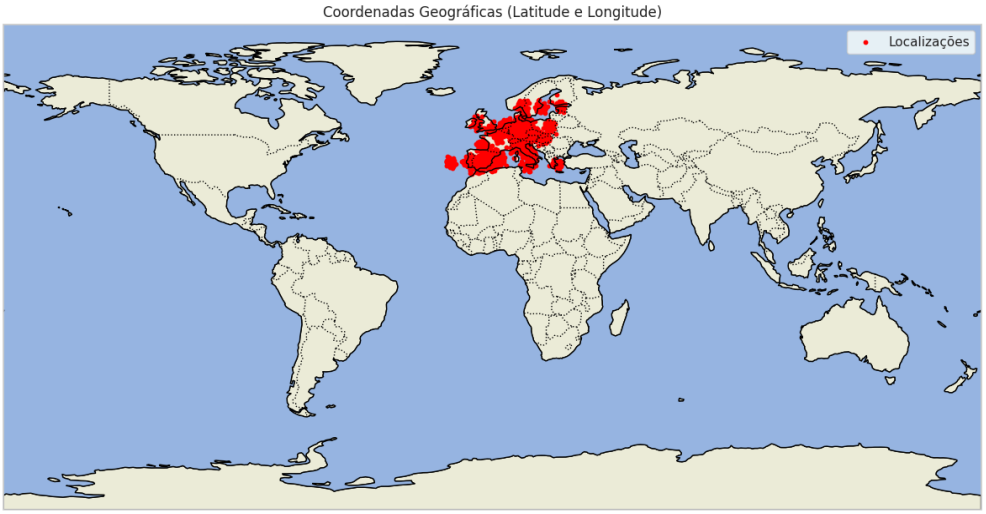

Figura 11 — Mapa de dispersão das localizações dos terminais

As coordenadas x/y de clientes e terminais permitem calcular a distância geográfica entre o cliente e o terminal da transação. Transações realizadas a grandes distâncias do padrão habitual do cliente são indicadores relevantes de fraude. Essa feature de distância deve ser derivada na etapa de feature engineering.

---

10. Conclusões e Próximos Passos

10.1 Principais Achados da EDA

- Taxa de fraude global: 2,26% — desbalanceamento severo exige SMOTE e/ou scale_pos_weight.
- 75,15% dos clientes foram expostos a ao menos uma transação fraudulenta no período.
- Volume financeiro total fraudado: R$ 376.210,13.
- Terminal 565: maior alerta — taxa de fraude 9,68x acima da média, 2° maior volume.
- Período noturno apresenta a maior taxa de fraude (2,43%) apesar do menor volume.
- TX_AMOUNT difere significativamente entre fraude e legítima (Mann-Whitney p = 0,003).
- Coordenadas geográficas permitem criar features de distância cliente-terminal.

10.2 Features Recomendadas para o Modelo

- Janelas temporais do cliente: volume e ticket médio nas últimas 1, 7 e 30 dias.
- Risco do terminal: taxa de fraude do terminal nas últimas 1, 7 e 30 dias (com delay de 7 dias para evitar leakage).
- Features temporais: hora da transação, período do dia, flag fim de semana, flag noite.
- Desvio de valor: z-score de TX_AMOUNT em relação ao histórico do cliente (mean_amount, std_amount).
- Distância geográfica entre cliente e terminal (x_customer_id / x_terminal_id).
- TX_AMOUNT_LOG: transformação log para reduzir assimetria.

10.3 Métricas de Avaliação

- Métrica principal: Average Precision (AUC-PR) — mais adequada que AUC-ROC para dados desbalanceados.
- Métrica secundária: Card Precision@K — precisão nas top K% transações com maior score.
- Threshold ótimo: derivar pela curva Precision-Recall, priorizando recall (F2-score).